



융합프로젝트 교과목 프로젝트 결과보고서



작품(과제)명 (Project Name)	국문명	CBS와 모방학습 기반 MAPF 비교분석 및 자율주행 로봇 적용 시스템		
	영문명	Comparative Analysis of CBS and Imitation-Learning-Based MAPF with Application to an Autonomous Mobile Robot System		
팀명(Team Name)	국문명	길막금지	영문명	NoDeadlock
작품제작기간	2026-1학기		작품작동 여부	☐ 작동 ☐ 비작동 ☐ 기타
교과목 구분	☐ 알파프로젝트(다학년 연구프로젝트) ☐ 캡스톤 디자인 ☐ 기타 ()			
과제 유형	☐ 산업체연계과제 ☐ 교수제시과제 ☐ 학생자유과제			

신청사항 (지도교수)

소 속	전기전자공학과	성 명	김광기 교수님
E-mail		연락처	

참가인원(학생)

No.	성명	소속학과	학번	휴대전화	E-mail	역할
1	김윤지	스마트모빌리티공학과	12243763	010-8131-2867	yoongi@inha.edu	팀장
2	김채은	스마트모빌리티공학과	12243766	010-8386-1008	codms1008@inha.edu	팀원
3	서인아	스마트모빌리티공학과	12243773	010-3171-1783	ina050828@inha.edu	팀원
4	임정빈	전기전자공학부	12221521	010-3152-6879	steam6879@inha.edu	팀원
5	백권희	컴퓨터공학과	12211629	010-5116-4664	semi466@naver.com	팀원
6						
7						
8						
9						
10						

미래자동차 혁신융합대학 사업단에서 주관하는 융합프로젝트 교과목 예산 지원과 관련하여 <프로젝트 결과보고서>를 작성하여 다음과 같이 제출합니다.

2026년 7월 8일

팀장명 : 김윤지 (서명/인)

미래자동차 혁신융합대학 사업단장 귀하

- ※ 프로젝트 결과보고서를 과제별로 1건씩 작성 요망
- ※ 팀원 중 팀장을 선정하고 각자 담당 역할을 역할 칸에 작성
- ※ 붙임. 프로젝트 결과 보고서 1부. (5 ~ 8page 이내로 작성 요망)

프로젝트 결과 보고서

팀 명 길막금지

작품(과제)명 CBS와 모방학습 기반 MAPF 비교분석 및 자율주행 로봇 적용 시스템

1. 개발동기 및 목적, 필요성

물류창고 자동화, 스마트 팩토리, 자율주행 로봇처럼 여러 로봇이 동일한 공간에서 동시에 이동하는 환경이 확대되고 있다. 이러한 다중로봇 환경에서는 목적지 도달뿐만 아니라 로봇 간 충돌 방지와 교착(deadlock) 상황 회피가 중요하며, 이를 해결하는 핵심 기술이 다중 에이전트 경로 계획(MAPF)이다.


기존 MAPF는 A*, Prioritized Planning, CBS와 같은 고전 알고리즘을 중심으로 연구되어 왔다. CBS는 충돌 없는 경로를 체계적으로 탐색할 수 있지만, 로봇 수가 증가하거나 맵이 복잡해질수록 계산 시간이 증가하는 한계가 있다. 반면 모방학습 기반 방법은 CBS가 생성한 경로 데이터를 학습하여 빠른 행동 예측이 가능하므로, 두 방식의 성능을 동일 환경에서 비교할 필요가 있다.

본 프로젝트는 CBS 기반 고전 MAPF와 행동복제 기반 모방학습 모델을 비교/분석하고, 향후 실제 소형 자율주행 로봇에 적용 가능한 다중로봇 경로계획 시스템으로 확장하는 것을 목표로 한다.

본 과제는 격자 기반 시뮬레이션 환경 구축, CBS 어댑터(atb033 solver 연동) 구현, 모방학습 모델 (MLP-> CNN-> DAgger-> navhint) 구현, 실제 로봇 시뮬레이터 연동, 표준 벤치마크 평가의 순서로 진행하였다.

1. CBS 파트:

CBS Team MAPF Pipeline



2. 과제 해결 방안 및 과정

Figure 1: CBS Team MAPF Pipeline

본 프로젝트에서 CBS(Conflict-Based Search)는 고전 탐색 기반 MAPF의 기준 알고리즘이자, 모방학습 모델 학습을 위한 전문가 경로 생성기로 사용하였다. CBS는 여러 에이전트의 시작점과 목표점, 장애물 정보를 입력받아 충돌 없는 경로 집합을 생성하므로, 이후 IL 모델이 학습할 expert path의 원천 역할을 한다. 본 프로젝트에서는 CBS 알고리즘 전체를 새로 구현하기보다, 검증된 오픈소스 atb033 CBS solver를 프로젝트의 맵/시나리오 형식에 맞게 연결하는 adapter 구조를 구현하였다.

CBS 파이프라인은 Map Generator → Scenario Loader → CBS Adapter → CBS Outputs → Simulator/IL의 흐름으로 구성하였다. Map Generator는 격자 지도와 에이전트의 start/goal scenario를 생성하고, Scenario Loader는 scenario 좌표를 프로젝트 내부 좌표계인 (row, col) 형식으로 변환한다. CBS Adapter는 이를 atb033 solver가 요구하는 [x, y] 기반 input.yaml 형식으로 변환하여 solver를 실행하고, 생성된 output.yaml을 다시 내부 좌표계 경로로 변환하여 paths.json으로 저장하였다.

생성된 CBS 경로는 두 가지 목적으로 활용하였다. 첫째, simulator에서 vertex collision, edge collision, deadlock 여부를 검증하기 위한 기준 경로로 사용하였다. 둘째, IL 팀이 모방학습 모델을 학습할 수 있도록 expert_handoff.json 및 expert_dataset.npz 형태의 expert data로 변환하였다. 초기 smoke test에서는 empty, sparse, dense, rooms, maze 및 고정 예제 scenario에 대해 CBS 경로 생성이 정상적으로 수행됨을 확인하였으며, 이를 통해 후속 IL 학습과 CBS-IL 비교 실험을 위한 기본 데이터 생성 파이프라인을 구축하였다.

2. IL 파트:

CBS팀이 생성한 전문가 경로 (expert_handoff.json/expert_dataset.npz)를 받아 (관측, 행동) 쌍으로 변환하고, 행동복제 (MLP)→ CNN→ DAgger 순으로 모델을 심화 구현하였다.

PRIMAL[2], DAgger[1] 원논문을 분석하여 관측 공간 (FOV 채널) 설계와 distribution shift 문제의 이론적 근거를 확립하고, 이를 바탕으로 v0.3 채널 표준 (벽/장애물, 다른 로봇 위치, 다른 로봇 목표 위치)을 설계하였다.

초기 데이터 (1,632샘플)에서 held-out accuracy 0.782(CNN)을 얻었으며, 데이터 다양화 스크립트로 시나리오를 332개까지 확장 (13,696샘플)하여 accuracy를 0.835까지 개선하였다. 이후 대형맵(16~32) 데이터를 추가로 보강하여 32x32 맵에서의 성공률을 최대 2배 (0.33→0.67) 향상시켰으며, 이는 학습맵이 작아 goal_dir 값의 분포가 좁았던 것(OOD 문제)이 원인이었음을 진단/해결한 결과이다.

시뮬레이터 팀에게 DAgger 학습에 필요한 MAPFSimulator 인터페이스 (reset/step/get_expert_actions)를 요청하여 연동한 뒤, DAgger를 반복 학습하였다. 그 결과 중간 혼잡 구간 (에이전트 6개)의 성공률을 0.40→0.64로 크게 개선하였다.

전체 실패 사례를 정밀 분석한 결과, 교착(deadlock)은 두 가지 성격으로 구분됨을 확인하였다: 로봇 간 충돌 회피 실패로 인한 협조 교착(데이터 확장/DAgger로 해결 가능)과, 목표가 벽 너머에 있어 우회가 필요하나 goal_dir(직선 방향 벡터)만으로는 표현할 수 없는 내비게이션 한계(데이터로는 해결되지 않는 구조적 문제)이다.

이 내비게이션 한계를 해결하기 위해 상태 표현 자체를 개선하는 navhint(내비게이션 힌트) 기법을 제안하였다. 기존의 목표까지 직선 벡터(goal_dir)를, 정적 맵에서 목표로부터 BFS(너비 우선 탐색)를 미리 계산해 얻은 “벽을 우회하는 다음 스텝 방향과 거리”로 대체하는 방식이다. 5x5 시야와 모델 구조는 그대로 유지하며, CBS 경로를 재사용하되 goal 피쳐만 새로 계산하므로 추가 연산 비용이 거의 없다. 이 navhint 기법을 적용한 결과, 기존에는 전혀 풀지 못했던 미로(maze) 맵의 성공률이 0.00→0.67로, 방 (room) 맵은 0.00→0.60으로 개선되어 내비게이션 한계를 실질적으로 해결하였다. 다만 이 표현 위에서는 DAgger가 오히려 성능을 저하시키는 것을 확인하였다.

3. 비교 실험

동일 벤치마크(MovingAI 표준셋)에서 CBS와 IL을 정면 비교한 결과, CBS는 최적 경로를 보장하지만 에이전트 수/밀도 증가에 지수적으로 느려지는 반면 (0.08s→9.6s), IL은 항상 1초 미만으로 평탄하게 동작하며 쉬운 구간에서는 makespan(경로 품질)도 CBS와 동등함을 확인하였다. 반대로 매우 어려운 맵 (maze 등)에서는 CBS조차 타임아웃되어 전문가 라벨 자체가 존재하지 않아 기존 IL 학습도 불가능한 구간이 있음을 확인하였다.

이를 근거로 저밀도 구간은 IL, 중밀도는 CBS, 그리고 CBS/IL 모두 실패하는 고밀도/대형맵 구간은 IL을 1차 시도로 사용하고 실패/충돌이 감지된 부분만 CBS로 국소 재해결하는 하이브리드 구조가 필요하다는 결론을 도출하였다.

3. 출품과제의 기술

알고리즘 및 AI 기술

- MAPF: vertex/edge collision, deadlock 분석 및 다중로봇 경로 계획
- CBS(atb033 오픈소스 solver): Conflict Tree 기반 최적 경로 탐색 알고리즘. 프로젝트 좌표계와 solver 좌표계를 변환하는 어댑터를 구현하여 연동하였다. (상세 흐름은 2번 항목 CBS 파트 참고).

- 모방학습/행동복제 (Behavioral Cloning): CBS 전문가 데이터 기반 지도학습
- CNN: 5x5x3 로컬 FOV 기반 공간 정보 보존 모델 (PRIMAL[2] 관측 설계 참고)
- DAgger[1]: CBS 재라벨링 기반 반복 학습으로 distribution shift 완화. 이를 위해 매 스텝 상호작용이 가능한 인터랙티브 시뮬레이터가 필요하여, IL팀이 시뮬레이터팀에 MAPFSimulator 추상 클래스(reset/step/get_expert_actions)의 구현을 요청하여 연동하였다.
- navhint(내비게이션 힌트): 목표까지의 직선 벡터 대신 BFS 기반 벽 우회 방향/거리를 goal 피처로 사용하는 상태 표현 개선 기법. 결정적이고 연산 비용이 낮은 “벽 회피 길찾기”는 BFS가 담당하고, 동적인 “다른 로봇 회피(협조)”는 정책이 학습하도록 역할을 분리하였다.

개발/평가 환경

- Python 3.12.6, PyTorch 2.6.0(CUDA), NumPy, PyYAML
- 표준 MAPF 벤치마크(MovingAI/Sturtevant): empty-8-8, random-32-32-10/20, room-32-32-4, maze-32-32-2
- 평가지표: accuracy, macro-F1, confusion matrix, action-accuracy, success-rate, makespan, 계산 시간, 교착률(협조/내비게이션 유형 구분), 잔여거리(rem)

산출물 (모델 체크포인트)

파일	학습 데이터	요점
mlp.pt	1.6k	MLP 베이스라인
cnn.pt	1.6k	CNN 베이스라인
cnn_diverse.pt	13.7k	데이터 확장
cnn_big.pt	27.7k(+큰맵)	대형맵 개선(goal_dir OOD 해결)
cnn_bigdense.pt	47k(+dense)	BC 최종(straight_goal_dir)
cnn_dagger_final.pt	47k+롤아웃	개방/저밀도 교착 회복
cnn_navhint.pt	flowdist 인코딩	최종 권장 모델 - 미로/방 항법 해결
cnn_dagger_navhint.pt	navhint+DAgger	navhint 위 DAgger(비권장, 참고용)

전체 파이프라인

[map_generator] 격자 지도, Start/ Goal 생성 -> [CBS 어댑터: atb033 solver 연동] 좌표 변환 (row,col <-> x,y) -> 전문가 경로 (path.json) 생성 -> [IL] states_grid (3x5x5) + goal_dirs(2) 추출 -> MLP/CNN 학습 -> 성능평가 -> [시뮬레이터: MAPFStepSimulator] reset/step/get_expert_actions 인터페이스로 연동 -> DAgger 반복 학습 (모델 rollout -> CBS 재라벨링 -> 재학습) -> navhint(BFS flow 힌트)로 goal 피처 재설계 -> 최종 모델 (cnn_navhint) 학습

CBS-Based MAPF Path Planning Framework




Figure 2: CBS-Based MAPF Path Planning Framework

FOV 채널 설계 (v0.3)

채널	의미
ch0	벽/장애물/맵 밖
ch1	다른 로봇의 현재 위치
ch2	다른 agent의 목표 위치 (내 목표는 goal_dir로 별도 제공)

4. 개념설계 및 상세설계(계산)

PRIMAL[2]의 관측 공간 설계를 참고하여 5x5 로컬 FOV 기반 channel 구조를 채택하였다. 초기 설계는 3 채널 (빈공간/장애물/다른 로봇)이었으나, 빈공간 채널이 나머지 두 채널로부터 유도 가능한 중복 정보임을 확인하고, PRIMAL이 제공하는 “주변 에이전트 목표 위치” 정보로 대체하였다(v0.3).

핵심 성능 지표 (held-out 기준, real_v03 N=303)

지표 정의: Accuracy(전체 정답률), Precision/Recall/F1(행동별 정밀도/재현율), macro-F1(5개 행동 F1 평균), Confusion Matrix(정답x예측 대조표)

모델	데이터 규모	Accuracy	macro-F1	상 F1	하 F1	좌 F1	우 F1	대기 F1
MLP	1,632	0.805	0.775	0.718	0.729	0.677	0.769	0.983
CNN	1,632	0.782	0.748	0.612	0.755	0.678	0.719	0.978
CNN (diverse)	13,696	0.835	0.803	0.731	0.800	0.689	0.812	0.983




Figure 3: 에폭별 학습 곡선 (MLP vs CNN) - MLP는 20에폭 이후 val loss 재상승(과적합), CNN은 60에폭까지 꾸준히 개선

Dagger[1]는 BC(행동복제)가 distribution shift로 인해 compounding error가 발생하는 한계를 CBS 재라벨링 기반 반복 학습으로 완화하는 방식이다.

대형맵 성능 진단: goal_dir OOD 문제

모델은 5x5 FOV만 관측하고 전역 정보는 goal_dir 하나에 의존하는데, 학습맵이 15x15 이하였던 관계로 goal_dir값이 최대 14에 머물렀다. 반면 32x32 대형맵에서는 최대 31까지 필요해, 학습 시 보지 못한 범위 (OOD)에서 실패가 발생함을 진단하였다. 큰 맵 데이터를 추가한 재학습(cnn_big.pt)으로 random-32-32-10 (4개 기준) 성공률이 0.33->0.67 (2배)로 개선되었다.

교착(Deadlock)의 두 가지 유형 - 협조 교착 vs 내비게이션 한계

전체 7개 모델을 open(빈 맵)부터 room/maze(벽이 많은 맵)까지 측정한 결과, 실패의 성격이 맵 구조에 따라 뚜렷이 갈렸다.

유형	정의	해결 방법
협조 교착 (COORD)	로봇끼리 서로 막혀 진행 못함	데이터 확장/ DAgger로 해결 가능
내비게이션 한계 (NAV)	목표 방향이 벽에 막혀 우회가 필요하나 직선 goal_dir로는 표현 불가	navhint (BFS flow 힌트)로 해결

맵	NAV 비율	해석
---	--------	----

empty-8-8	0.00	벽이 없어 교착이 전부 협조 문제
random-32-32-10/20	0.21~0.71	밀도 증가에 따라 NAV 비중 상승
room/maze	0.54~0.84	벽 구조가 많아 대부분 내비게이션 한계




Figure 4: 교착 유형/ 협조 교착 사례 (CBS expert vs CNN - BC (1.6k) stuck vs CNN-bigdense(47k) solved 비교)

상태 표현 개선: navhint(BFS flow 힌트) - 최종 핵심 성과

교착 분석에서 room/maze의 실패는 데이터/ 학습 시간/ 시야 크기가 아니라 상태 표현 자체의 한계로 진단되었다. 검증 실험으로 IL 롤아웃 스텝을 160→600으로 늘려도 결과가 완전히 동일했고 (정책이 초반 교착 상태에 갇혀 고정), CBS의 타임아웃을 8초→60초로 늘려도 maze n8은 여전히 실패하여, 이 문제가 “시간”이 아니라 “표현”의 문제임을 확인하였다.

이에 따라 목표까지의 방향을 나타내는 goal_dir을, 정적 맵에서 목표로부터 BFS를 1회 계산해 얻은 “벽을 우회하는 다음 스텝 방향(flow)”으로 대체하는 navhint 기법을 설계하였다. 여러 인코딩 방식을 비교한 결과, 방향과 거리를 함께 담은 flowdist 방식이 가장 우수하였다(직선 벡터를 함께 포함한 4채널 방식은 개방맵에는 유리하나 미로에서 오히려 직선 신호에 이끌려 성공률이 0으로 회귀하는 문제가 있었다).

인코딩	empty-8-8	random-32-32-20	room-32-32-4	maze-32-32-2
straight(v0.3, 직선)	0.60	0.15	0.05	0.00
flow(방향만)	0.45	0.75	0.60	0.65
flowdist(방향+거리)	0.55	0.75	0.60	0.65
both(직선+flow 4채널)	0.70	0.50	0.25	0.00(실패)

최종 비교 - straight vs navhint(BC) vs navhint+DAgger

맵(에이전트)	straight	navhint-BC	navhint-DAgger
maze-32-32-2(4)	0.00	0.67	0.33(하락)
room-32-32-4(4)	0.00	0.60	0.27(하락)
random-32-32-20(4)	0.20	0.80	0.33(하락)
empty-8-8(4)	0.60	0.60	0.73

navhint 위에서 DAgger가 오히려 성능을 저하시키는 원인을 추가로 검증하였다. DAgger는 정책이 실제로 방문한 상태를 CBS에게 재질의하여 라벨을 얻는 방식인데, CBS 자체가 미로,방 구조를 풀지 못해(타임아웃) 해당 구간에는 애초에 전문가 라벨이 존재하지 않는다. 따라서 DAgger가 추가하는 학습 데이터는 CBS가 풀 수 있는 개방, 저밀도(협조 위주) 맵에 편향되며, 이 협조 데이터가 navhint의 핵심 강점인 “flow를 따라 벽을 우회하는 항법 능력”을 오히려 희석시키는 것으로 확인되었다. 이는 DAgger의 오류가 아니라, 전문가(CBS)가 라벨링할 수 없는 영역에서 발생하는 구조적 한계이다.

결론적으로 navhint 기반 BC 모델(cnn_navhint.pt)을 최종 권장 모델로 선정하였으며, 이 모델은 5x5시야

와 경량 모델 구조를 그대로 유지하면서도, 4에이전트 기준 기존에 풀지 못했던 미로/방 구간의 성공률을 0에서 0.6이상으로 끌어올렸다. 다만 8에이전트 이상의 고밀도 미로/방 구간은 여전히 미해결로 남았다. 또한 개방 맵에서의 극심한 혼잡(예: empty-8-8, 8개 이상)은 navhint로도 해결되지 않아, 이는 항법 문제가 아닌 순수한 다중 에이전트 협조 문제로서 별도의 접근이 필요함을 확인하였다.

시뮬레이터에서 실제 경로 수행 성능 확인 (MovingAI 표준 벤치마크)

맵	에이전트	Action-accuracy	Success-rate
empty-8-8	2	0.827	0.950
empty-8-8	4	0.871	0.550
random-32-32-10	2	0.791	0.700

CBS vs IL 정면 비교 - IL은 CBS보다 16-250배 빠르며, 쉬운 구간에서는 makespan(경로 품질)도 CBS와 동일한 수준을 보인다. 반면 CBS는 혼잡 상황에 훨씬 강건하여 random-32-32-20(8개)까지 성공률 1.00을 유지하지만, maze처럼 매우 어려운 맵에서는 CBS조차 타임아웃되어 실패한다(전문가 라벨 자체가 없어 기존 IL도 학습 불가능한 구간이었다). navhint는 이 구간을 4에이전트 기준 0.00->0.67로 열었으나, 8에이전트 이상 고밀도 미로는 여전히 미해결이다.

맵(밀도)	에이전트	CBS 성공/시간	IL(straight) 성공/시간
empty-8-8 (0%)	2	1.00/0.08s	1.00/0.004s
random-32-32-20 (20%)	8	1.00/1.3s	0.00/ 0.5s
maze-32-32-2 (35%)	8	0.00(timeout,8s)	0.00/ 0.45s




Figure 5: CBS vs IL 성공률 비교 그래프(밀도별), CBS vs IL 실행 시간 비교 그래프

BC vs DAgger 비교 (empty-8-8, straight 표현, BC=13.7k 기준)

에이전트	BC success	DAgger success	변화
4	0.56	0.68	+0.12
6	0.40	0.64	+0.24
8	0.32	0.24	-0.08 (극혼잡에서 악화)




Figure 6: Dagger 전후 성공률/교착률 비교 그래프

결과 분석

- **CBS 대비:** CBS는 makespan 최적성을 보장하지만 에이전트 수/밀도 증가에 지수적으로 느려지며, 매우 어려운 맵에서는 타임아웃으로 실패한다. IL은 항상 1초 미만으로 평탄하다 - 안정성(CBS) vs 실시간성(IL) 트레이드오프가 뚜렷함
- **강점 구간 분리:** 저밀도/소수 에이전트는 IL이 빠르면서 품질 동등, 중밀도는 CBS가 우세, 미로/방처럼 매우 어려운 구간은 CBS/IL 모두 실패했으나 navhint 적용 후 IL만으로 해결 가능해짐
- **교착의 성격 구분과 해결:** 개방 맵의 교착은 데이터/Dagger로 해결되고, 벽이 많은 맵의 내비게이션 한계는 navhint(BFS flow 힌트)로 해결되어, 두 가지 실패 유형에 각각 다른 해법이 유효함을 확인함.
- **navhint 인코딩 설계의 중요성:** 방향 정보만 단순히 추가하는 것이 아니라, 어떤 정보를 얼마나 담을지 (flow vs flowdist vs both)에 따라 결과가 크게 갈림 - 직선 벡터를 섞으면 오히려 미로에서 성능이 붕괴함을 확인
- **Dagger와 navhint의 상호작용:** Dagger가 항상 유리한 것은 아니며, 전문가(CBS)가 라벨링할 수 없는 영역(미로 등)에서는 오히려 학습 분포를 협조 위주로 편향시켜 navhint의 항법 강점을 훼손함 - 알고리즘의 개선효과는 전문가의 능력 범위 내에서만 유효함을 확인

실패 사례

- **CBS 실패:** maze/다수 에이전트/대형 맵에서 타임아웃 발생. (예: maze-32-32-2 8개는 CBS도 8초 내 해를 찾지 못함)
- **BC 모델 실패 (협조 교착, 해결됨):** 데이터가 적을 때 (1.6k) empty-8-8에서도 로봇끼리 서로 막혀 교착 발생. 데이터를 47k까지 늘리고 Dagger를 적용하여 크게 개선
- **BC 모델 실패 (내비게이션 한계, 해결됨):** room/maze에서 직선 goal_dir만으로는 벽 우회 경로를 학습할 수 없어 전 모델 성공률 0에 가까웠으나, navhint 적용으로 0.6 이상까지 개선
- **여전히 남은 한계:** 개방 맵의 극심한 혼잡 (empty-8-8, 8개 이상)은 navhint/Dagger 모두 해결하지 못함 - 순수 다중 에이전트 협조 문제로서 별도 접근 필요

한계점

- navhint는 정적 맵에 대한 BFS 사전 계산에 의존하므로, 맵이 실시간으로 변화하는 동적 환경에는 추가 검증이 필요함
- 개방 맵의 초고밀도 혼잡 (8개 이상)은 여전히 미해결 - 항법이 아닌 순수 다중 에이전트 협조 알고리즘 개선이 필요함
- Dagger CBS가 라벨링 가능한 범위 내에서만 효과적이며, CBS 자체가 실패하는 구간(대형맵 + 다수 에이전트 + 복잡한 구조)은 여전히 미해결

5. 재료구입 및 활용 내역	본 프로젝트는 소프트웨어 (시뮬레이션/알고리즘) 기반 연구로 진행되어, 별도의 물리적 재료 구입 내역은 없다.
6. 프로젝트 결과와 미래자동차 분야와의 연계 방향	본 프로젝트에서 검증한 CBS-IL 하이브리드 경로계획 방법론은 자율주행 자동차의 군집주행(platooning), 발렛파킹 시스템, 스마트 물류터미널 내 자율 주행 셔틀 등 다수의 자율주행체가 동일 공간을 공유하는 미래자동차 응용분야에 직접 연계될 수 있다. 특히 본 연구에서 발견한 navhint(상태 표현 개선) 기법은, 복잡한 도로망이나 주차장처럼 구조화된 환경에서 자율주행체가 저비용으로 목적지까지의 우회 경로를 인지하도록 하는 데 응용 가능하며, 저밀도 구간은 학습 기반 경량 모델로 빠르게 처리하고, 고밀도/ 충돌 위험 구간에서만 고전 탐색으로 정밀 재계산하는 하이브리드 구조는 실시간성이 요구되는 자율주행 환경에서 안전성과 연산 효율을 동시에 확보하는 방향으로 확장 가능하다.
7. 향후 미래자동차 관련 경진대회, 학술대회 연계 계획(안)	본 프로젝트의 후속 확장 방향으로 The 4th Koh Young AI Contest 2026 참가를 검토하고 있다. 해당 대회는 ICROS가 주관하고 Koh Young Technology가 후원하는 AI 경진대회로, 제조 검사 공정에서 제한된 계산 자원을 고려한 효율적 의사결정 문제를 다룬다. 본 연구의 MAPF 경로계획 문제와 대회 주제가 직접적으로 동일하지는 않지만, CBS와 모방학습 기반 모델을 비교하며 계산 시간, 성공률, 충돌률, 교착률 등을 분석한 경험은 MAPF 문제와 연계될 수 있다. 따라서 본 프로젝트 결과를 바탕으로 resource-aware AI, real-time decision making, multi-agent coordination 관점의 후속 연구 및 경진대회 참가를 검토 중이다.
8. 기타	본 과제는 CBS팀(3인)과 IL팀(2인)으로 역할을 분담하여 진행하였다. CBS 팀 - 김윤지 - 맵 제너레이터 제작 (환경 구축 및 시각화) - 임정빈 - 시뮬레이터 구현(규칙 검사), DAgger용 MAPFSimulator 구현 - 백권희 - CBS 오픈소스 통합: atb033 solver 연동, 좌표 변환 어댑터 구현 IL 팀 - 서인아 - 논문 분석 및 설계 근거 수립(PRIMAL, DAgger), 실험 결과 분석 - 김재은 - 모델 구현: MLP/CNN/DAgger 파이프라인, 데이터 다양화/대형맵 확장 후속 계획 - 개방 맵의 초고밀도 혼잡(8개 이상)을 해결하기 위한 다중 에이전트 협조 알고리즘 개선을 검토할 예정 - navhint를 동적 환경 (장애물이 실시간으로 변화하는 상황)에서도 검증할 예정 - CBS와 IL 모두 실패하는 “대형맵+다수 에이전트+국도로 복잡한 구조” 구간을 대상으로, IL(navhint 포함) 1차 시도 + 실패 시 국소 CBS 재해결 방식의 하이브리드 프로토타입을 구현/검증할 예정 - 이번 학기 시뮬레이션 기반 검증 결과를 바탕으로, 후속 학기에는 실제 소형 자율주행 로봇에 경로계획 시스템을 이식하는 단계로 발전시킬 예정
9. 참고문헌	[1] Ross, S., Gordon, G., Bagnell, D. (2011), “A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning”, AISTATS. [2] Sartoretti, G. et al. (2019), “PRIMAL: Pathfinding via Reinforcement and Imitation Multi-Agent Learning”, IEEE RA-L, 4(3):2378-2385. [3] Sven Koenig, Nathan Sturtevant, Ariel Felner et al., “MAPF.info: Multi-Agent Path Finding Home Page,” MAPF.info, https://mapf.info/index.php/Main/HomePage, accessed July.8,2026. [4] atb033, “Multi-Agent Path Planning in Python,” GitHub, https://github.com/atb033/multi_agent_path_planning, accessed July.8,2026. [5] 신동철·문형일·강성규·이성원·양현석·박찬욱·남문식·정길수·김영재(2022), “다중에이전트 경로탐색(MAPF) 기반의 실내배송로봇 군집제어 구현”, 「로봇학회 논문지」, 17(4):407-416. [6] 이원종·심준열·남창주(2024), “퍼즐 휴리스틱스: 대규모 환경을 위한 효율적인 다중 에이전트 경로 탐색 알고리즘”, 「로봇학회 논문지」, 19(3):281-286.